

# **Aplicações de Análise Fatorial Bayesiana**

Carlos de Moura

2026-06-30

# Índice

|          |                                                      |           |
|----------|------------------------------------------------------|-----------|
| <b>1</b> | <b>Sobre</b>                                         | <b>3</b>  |
| 1.1      | Motivação . . . . .                                  | 3         |
|          | <b>Referências</b>                                   | <b>4</b>  |
|          | <b>Licença</b>                                       | <b>5</b>  |
| <b>2</b> | <b>Modelos básicos</b>                               | <b>6</b>  |
| 2.1      | Análise fatorial exploratória . . . . .              | 6         |
|          | Identificabilidade . . . . .                         | 7         |
|          | O papel da heterocedasticidade . . . . .             | 8         |
| 2.2      | Modelos confirmatório e semi-confirmatório . . . . . | 8         |
|          | Criando grupos via prioris informativas . . . . .    | 9         |
| <b>3</b> | <b>Aplicação 1: dependência</b>                      | <b>12</b> |
| <b>4</b> | <b>Aplicação 2: regularização</b>                    | <b>13</b> |

# 1 Sobre

Este é o [material auxiliar](#) do seminário de Tópicos Especiais em Estatística: Estatística Multivariada (DEST-UFMG, 2026/1, EST 865). O tema é análise fatorial Bayesiana, em específico algumas aplicações vistas na literatura. Este [quarto book](#) está dividido da seguinte forma:

- Introdução dos modelos mais básicos, e identificabilidade;
- Introdução de dependência entre os parâmetros;
- Seleção de modelos via prioris regularizadoras;

Usaremos dados do INMET como um exemplo motivador ao longo do texto.

## 1.1 Motivação

Porquê fazer análise fatorial do jeito Bayesiano?

- ~~porque é o jeito correto de fazer estatística;~~
- A inclusão de dependências temporais/espaciais em cargas e fatores ocorre naturalmente via prioris;
- A regularização de coeficientes também pode ser feita via prioris informativas, o que permite um modelo que faz seleção de fatores;
- Extensão para um modelo de regressão e análise fatorial.

## Referências

- Carvalho, C. M., Chang, J., Lucas, J. E., Nevins, J. R., Wang, Q., & West, M. (2008). [High-dimensional sparse factor modeling: Applications in gene expression genomics](#). *J. Am. Stat. Assoc.*, 103(484), 1438–1456. Informa UK Limited.
- Lopes, H. F. (2014). [Modern Bayesian Factor Analysis](#). Em I. Jeliaskov & X.-S. Yang (Eds.), *Bayesian Inference in the Social Sciences* (pp. 115–140). Hoboken, NJ: John Wiley & Sons.
- Mayrink, V. D., Panaro, R. V., & Costa, M. A. (2020). Structural equation modeling with time dependence: an application comparing Brazilian energy distributors. *AStA Advances in Statistical Analysis*. Obtido de <https://link.springer.com/article/10.1007/s10182-020-00377-2>

# Licença

Este trabalho está licenciado sob a licença [Creative Commons Atribuição 4.0 Internacional \(CC BY 4.0\)](https://creativecommons.org/licenses/by/4.0/).



## 2 Modelos básicos

### 2.1 Análise fatorial exploratória

No modelo de análise fatorial com apenas um fator, assumimos que

$$X = \alpha\lambda + \epsilon$$

ou, equivalentemente,

$$X_{i,j} | \{\alpha, \lambda, \sigma^2\} \sim \text{Normal}(\alpha_i \lambda_j, \sigma_i^2),$$

em que:

- $X \in \mathbb{R}^{n \times m}$  é a matriz de observações;
- $\alpha \in \mathbb{R}^n$  é a matriz das cargas;
- $\lambda \in \mathbb{R}^m$  é a matriz de escores;
- $\epsilon \in \mathbb{R}^{n \times m}$  é a componente estocástica do modelo, em que assumimos que  $\epsilon_{i,j} \sim N(0, \sigma_i^2)$  independentes e escrevemos  $\sigma^2 = (\sigma_1^2, \dots, \sigma_n^2)'$ .

#### **i** Nota

Embora estejamos assumindo normalidade nos exemplos dessa seção, outras distribuições podem ser usadas para escrever a verossimilhança do nosso modelo. Nesse sentido (e analogamente aos MLGs), poderíamos ter algo do tipo

$$X_{i,j} | \{\alpha, \lambda, \sigma^2\} \sim FE\left(g(\alpha_i \lambda_j), \phi_i\right),$$

em que  $FE$  é alguma distribuição da família exponencial,  $\phi_i$  é um parâmetro de precisão/escala e  $g$  uma função de ligação que faça sentido.

## Identificabilidade


Assim como seu análogo frequentista, o modelo acima padece de falta de identificabilidade. Isso ocorre pois  $\alpha\lambda = \alpha QQ^\top \lambda$  para qualquer  $Q$  ortogonal. Um exemplo de como isso pode afetar a estimação da distribuição posterior é mostrado abaixo.

```
data {  
  int n;  
  vector[n] x;  
  real mu_b;  
}  
parameters {  
  real<lower=0> a;  
  real b;  
}  
model {  
  x ~ normal(a*b, 1);  
  a ~ normal(0, 1);  
  b ~ normal(mu_b, 1);  
}
```

```
mod = readRDS(here::here("modIdent.rds"))  
  
set.seed(12345)  
  
x = rnorm(100, 1)  
  
out = capture.output({  
  rstan::sampling(mod, data = list(n = length(x), x = x, mu_b = 0), chains = 1, seed = 12345)  
  rstan::extract(pars = c("a", "b"), permuted = FALSE) |>  
  drop() |>  
  plot(main = "posterior a partir de prioris iguais")  
})  
  
out = capture.output({  
  rstan::sampling(mod, data = list(n = length(x), x = x, mu_b = 100), chains = 1, seed = 12345)  
  rstan::extract(pars = c("a", "b"), permuted = FALSE) |>  
  drop() |>  
  plot(main = "posterior a partir de prioris informativas")  
})
```

No simples exemplo acima não tivemos problema de convergência das cadeias

Embora o modelo descrito acima



### 🔥 $a$ ou $-a$ ?

Embora seja possível haver dados com cargas positivas e negativas em um mesmo grupo, em modelos com dados longitudinais naturais. Isso está associado a uma espécie de relação suave entre as variáveis.

Lembre-se que uma carga positiva indica uma correlação positiva entre a variável e seu fator.

Assim, assumimos as seguintes priors:

$$\begin{aligned}\alpha &\sim N_n(0, V_\alpha), \\ \lambda &\sim N_m(0, v_\lambda), \\ \sigma^2 &\sim Gama_n(\epsilon, \epsilon),\end{aligned}$$

em que  $v_\lambda \ll V_\alpha$  e  $\epsilon$  é um número positivo pequeno, de modo a garantir falta de informação.

## O papel da heterocedasticidade

A heterocedasticidade pode ser uma ferramenta valiosa para a avaliação da qualidade do ajuste do modelo. Na medida em que  $\sigma_i$  é o desvio padrão de  $X_{i,j}$  em relação a  $\alpha_i \lambda_j$  (que é a média estimada levando em consideração todas as variáveis), interpretamos  $\sigma_i$  como uma espécie de variância residual, uma variância dos dados não explicada pelo modelo de análise fatorial.

## 2.2 Modelos confirmatório e semi-confirmatório

Caso desejemos adicionar mais de um fator ao nosso modelo, uma extensão natural do modelo confirmatório é feita com as seguintes alterações (considerando  $r$  fatores).

- $\alpha \in \mathbb{R}^{n \times r}$  é a matriz das cargas;



- $\lambda \in \mathbb{R}^{r \times m}$  é a matriz de escores.

Note também que, agora, a média da variável resposta é decomposta em efeitos fatoriais ponderados pelas cargas.

$$\begin{aligned} E[X_{i,j} \mid \alpha, \lambda, \sigma^2] &= (\alpha\lambda)_{i,j} \\ &= \sum_{\delta=1}^r \alpha_{i,\delta} \lambda_{\delta,j} \\ &= \alpha_{i,1} \lambda_{1,j} + \dots + \alpha_{i,r} \lambda_{r,j}. \end{aligned}$$

Nesse sentido, as cargas têm uma dupla interpretação:


- nível de associação da variável com aquele fator;
- correção de escala, ajustar a escala do fator para a escala da variável resposta.

Ambas interpretações são apropriadas: uma carga mais alta não necessariamente significa uma maior associação entre variável e fator (pode decorrer de um ajuste de escala), mas uma carga baixa em valor absoluto significa necessariamente uma falta de associação entre eles.


## Criando grupos via priors informativas

**i** Um classificador fatorial


O modelo semi-confirmatório é (também) um modelo de classificação



(a) Modelo confirmatório




(a) Modelo semi-confirmatório



(a) Modelo confirmatório

Aplicação com dados de temperatura (modelo confirmatório por regiões do país, modelo semi-confirmatório por altitude)



(a) Modelo semi-confirmatório

### 3 Aplicação 1: dependência

Mayrink, Panaro, & Costa (2020) apresenta como o modelo CAR pode ser usado para criar estruturas de dependência tanto nas cargas quanto nos escores. O esquema CAR preconiza que se  $\{Z(A_i)\}_i$  é um Campo Markoviano de forma

$$Z(A_i) \mid Z(A_{(-i)}) \sim N \left( \mu_i + \sum_{j=1}^n c_{ij}(Z(A_j) - \mu_j), \tau_i^2 \right),$$

Então a estrutura de covariância de  $Z = (Z(A_1), \dots, Z(A_n))$  é dada por

$$\text{Cov}(Z) = [D(W) - \rho W]^{-1},$$

em que  $W$  é a matriz de vizinhanças e  $D(W)$  uma matriz diagonal com as somas das linhas de  $W$  e  $\rho$  depende das escolhas de  $c_{ij}$  e é tal que  $|\rho| < 1$ .

$$(\alpha_{\emptyset k}, \alpha_{0k})^T \sim \text{Normal}_n(0, B_k), \quad B_k = \begin{bmatrix} B_{k,11} & B_{k,12} \\ B_{k,21} & B_{k,22} \end{bmatrix}.$$

$$\alpha_{\emptyset k} \mid \alpha_{0k} \sim N_{|G_k \cup G_E|}(0, B_{\emptyset k}),$$

em que  $B_{\emptyset k} = B_{k,11} - B_{k,12} B_{k,22}^{-1} B_{k,21}$  e  $G_k$  e  $G_E$  é o conjunto de índices das variáveis associadas aos grupos  $k$  e extra, respectivamente.

Os escores da aplicação de Mayrink et al. (2020) representam anos. Os autores fazem uma estrutura de vizinhança entre os tempos de modo que  $t_i$  é vizinho de  $t_{i-1}$  e  $t_{i+1}$ .

$$\lambda_{i,\cdot} \sim N_m \left( 0, v_\lambda [D(W_\lambda) - \rho_\lambda W_\lambda]^{-1} \right).$$

$v_\lambda$  é adicionado por questões de identificabilidade, de modo a controlar os elementos da diagonal da matriz CAR.

## 4 Aplicação 2: regularização

Carvalho et al. (2008) apresenta uma proposta de prioris regularizadoras para as cargas.

$$\begin{aligned}\alpha_{g,j} &\sim (1 - \pi_{g,j})\delta_0(\alpha_{g,j}) + \pi_{g,j} \text{Normal}(\alpha_{g,j} \mid 0, \tau_j), \\ \pi_{g,j} &\sim (1 - \rho_j)\delta_0(\pi_{g,j}) + \rho_j \text{Beta}(\pi_{g,j} \mid a_j m_j, a_j(1 - m_j)).\end{aligned}$$




Figura 4.1: Breast cancer hormonal pathways. Skeleton of the fitted model for the 250 selected genes and 12 factors. (a) Binary heatmap of thresholded approximate posterior loading probabilities,  $\mathbf{1}(\hat{\pi}_{g,j} > 0.99)$ . (b) Heatmap of approximate posterior means of significant gene-factor loadings,  $\hat{\alpha}_{g,j}$ .